Q

5 Quizz 2. Mínimos Cuadrados Objetivo.

- Entender en qué consiste el ajuste de rectas por el método de mínimos cuadrados.
- Realizar una implementación de las matemáticas requeridas en este método.
- Probar la implementación con datos generados de manera sintética.

Mínimos cuadrados by <u>Luis M. de la Cruz</u> is licensed under <u>Attribution-ShareAlike 4.0 Inter</u>national **(cc)** (i) (1)







Trabajo realizado con el apoyo del Programa UNAM-DGAPA-PAPIME PE101922

6 Introducción.

El **método de mínimos cuadrados** se utiliza para ajustar rectas a series de datos presentados en la forma (x,y)como en la siguiente tabla:

x_0	x_1	x_2	•••	x_N
y_0	y_1	y_2		y_N

Este tipo de datos pueden provenir de diferentes fuentes como estudios geofísicos en campo, estudios experimentales en laboratorio, obtención de datos mediante encuestas, observación de fenómenos naturales, etc. La idea es estudiar como una variable depende de la otra.

Una posibilidad es que la variación sea lineal es decir: y = mx + b.

Sin embargo, en la mayoría de los casos no es posible obtener una recta exacta que pase por todos los puntos.

Para ello, el método de mínimos cuadrados nos proporciona con una metodología para obtener la mejor recta que represente a todos los puntos del conjunto de datos.

7 Conjuntos de datos.

Para esta actividad vamos a generar de manera sintética 4 conjuntos de datos. Usaremos la función np.random.rand() de numpy.

```
import numpy as np
import matplotlib.pyplot as plt
from macti.evaluation import *
```

```
quizz = Quizz('q2', 'HeCompA', 'local')
```

```
# Total de datos de cada conjunto
N = 20
# Fijamos la semilla para obtener los mismos valores siempre
np.random.seed(0)
# Conjunto 0
x0 = np.linspace(0,10,N)
y0 = x0 + np.random.randn(N)*2
# Conjunto 1
x1 = np.random.randn(len(x0))*10
y1 = np.random.randn(len(x0))*10
# Conjunto 2
x2 = np.arange(0,N)*100
y2 = -x2 + np.random.randn(N)*500
# Conjunto 3
x3 = np.array([i for i in range(N)])
y3 = np.random.rand(N)*0.5-0.5
```

```
print('\nArreglo x0 :\n{}'.format(x0))
print('Arreglo y0 :\n{}'.format(y0))

print('\nArreglo x1 :\n{}'.format(x1))
print('Arreglo y1 :\n{}'.format(y1))

print('\nArreglo x2 :\n{}'.format(x2))
print('Arreglo y2 :\n{}'.format(y2))

print('\nArreglo x3 :\n{}'.format(x3))
print('Arreglo y3 :\n{}'.format(y3))
```

```
Arreglo x0:
[ 0.
           0.52631579 1.05263158 1.57894737 2.10526316 2.63157895
 3.15789474 3.68421053 4.21052632 4.73684211 5.26315789 5.78947368
 6.31578947 6.84210526 7.36842105 7.89473684 8.42105263 8.94736842
 9.47368421 10.
                   1
Arreglo y0 :
5.05807157 3.38149611 4.00408861 5.55803911 5.55124504 8.6980207
 7.83786492 7.0854553
                     8.25614752 8.5620855 11.40921078 8.53705189
10.09981961 8.29180852]
Arreglo x1:
[-25,52989816
             6.53618595 8.64436199 -7.4216502
                                             22,69754624
-14.54365675
             0.45758517 -1.8718385
                                  15.32779214 14.6935877
```

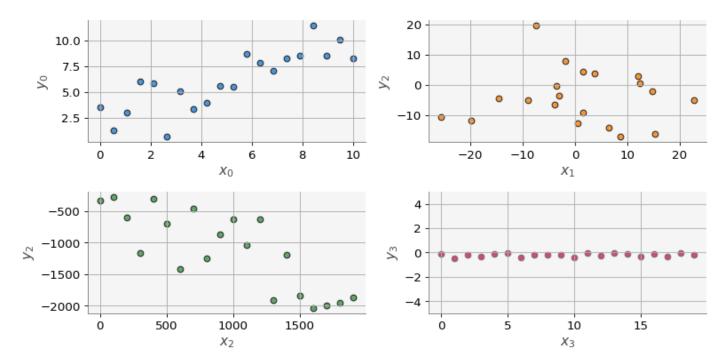
```
1.54947426 3.7816252 -8.87785748 -19.80796468 -3.47912149
  1.56348969 12.30290681 12.02379849 -3.87326817 -3.02302751]
Arreglo y1:
[-10.48552965 - 14.20017937 - 17.06270191 19.50775395 - 5.09652182
 -4.38074302 -12.5279536
                           7.77490356 -16.13897848 -2.1274028
 -8.95466561 3.86902498 -5.10805138 -11.80632184 -0.28182228
               0.66517222 3.02471898 -6.34322094 -3.62741166]
  4.28331871
Arreglo x2:
   0 100 200 300 400 500 600 700 800 900 1000 1100 1200 1300
1400 1500 1600 1700 1800 1900]
Arreglo y2:
[ -336.23022389 -279.77658077 -606.57314102 -1163.14130117 ]
 -311.28692887 -700.8904681 -1415.09917348 -468.60887224
-1253.64918219 -874.0273021 -635.45471891 -1035.50854462
 -630.29965773 -1917.41291018 -1198.82917941 -1842.40504547
-2035.39857459 -1989.42483238 -1955.77626606 -1871.917328891
Arreglo x3:
[ 0 1 2 3 4 5 6 7 8 9 10 11 12 13 14 15 16 17 18 19]
Arreglo y3:
[-0.08552999 - 0.49765226 - 0.16109173 - 0.36499601 - 0.13240299 - 0.01890573
-0.37562343 -0.21192133 -0.20397903 -0.21387405 -0.38845918 -0.02362549
-0.27643731 -0.07679566 -0.15026036 -0.35128152 -0.09310109 -0.30174713
-0.0594484 -0.209363561
```

8 Análisis exploratorio.

```
plt.figure(figsize=(10,5))
ax0 = plt.subplot(221)
ax0.scatter(x0, y0, fc = 'C0', ec='k', alpha=0.75)
ax0.set xlabel('$x 0$')
ax0.set_ylabel('$y_0$')
ax0.grid()
ax1 = plt.subplot(222)
ax1.scatter(x1, y1, fc = 'C1', ec='k', alpha=0.75)
ax1.set_xlabel('$x_1$')
ax1.set ylabel('$y 2$')
ax1.grid()
ax2 = plt.subplot(223)
ax2.scatter(x2, y2, fc = 'C2', ec='k', alpha=0.75)
ax2.set xlabel('$x 2$')
ax2.set_ylabel('$y_2$')
ax2.grid()
ax3 = plt.subplot(224)
```

```
ax3.scatter(x3, y3, fc = 'C3', ec='dimgrey', alpha=0.75)
ax3.set_xlabel('$x_3$')
ax3.set_ylabel('$y_3$')
ax3.set_ylim(-5,5)
ax3.grid()

plt.tight_layout()
plt.show()
```



9 Valores de m y b óptimos.

Los valores de la pendiente y de la ordenada al origen de la recta que mejor aproxima a un conjunto de datos están dados por las siguientes fórmulas:

$$m = \frac{\sum_{i=1}^{N} x_i (y_i - \bar{y})}{\sum_{i=1}^{N} x_i (x_i - \bar{x})}$$
(1)

$$b = \bar{y} - m\bar{x} \tag{2}$$

donde $ar{y}=rac{1}{N}\sum_{i=1}^N y_i$ y $ar{x}=rac{1}{N}\sum_{i=1}^N x_i$ representan el valor medio de los datos.

Podemos usar los conjuntos de datos definidos antes para calcular m y b y con ello obtener la recta que ajusta los datos.

9.1 Ejercicio 1.

Calcular la media del conjunto de datos x_0, y_0 . Almacenar las medias en las variables X y Y.

```
### BEGIN SOLUTION
### FileAnswer definition
# Se crea un objeto para guardar las respuestas, solo una vez.
file_answer = FileAnswer()
#file_answer.verb = 0
# Media de x
X = 0.0
for xi in x0:
   X += xi
X /= N
# Media de y
Y = 0.0
for yi in y0:
    Y += yi
Y /= N
file_answer.write('1', X, 'Revisa la definición de la media y tu implementación p
file_answer.write('2', Y, 'Revisa la definición de la media y tu implementación p
# END SOLUTION
print('Media de x: {}'.format(X))
print('Media de y: {}'.format(Y))
```

Media de x: 5.0

Media de y: 6.138669185891269

```
quizz.eval_numeric('1', X)
quizz.eval_numeric('2', Y)
```

1 | Tu resultado es correcto.

2 | Tu resultado es correcto.

9.2 Ejercicio 2.

Calcular la pendiente m del conjunto de datos x_0 , y_0 usando la fórmula (1). Almacenar la pendiente en la variable m.

Pendiente m: 0.7725548289646033

```
quizz.eval_numeric('3', m)
```

3 | Tu resultado es correcto.

9.3 Ejercicio 3.

Calcular la ordenada al origen b del conjunto de datos x_0,y_0 usando la fórmula (2). Almacenar la pendiente en la variable b.

```
# Cálculo de b
# b = ...
### BEGIN SOLUTION
# Cálculo de b
b = Y - m * X

file_answer.write('4', b, 'Revisa la fórmula para el cálculo de la ordenada al or
### END SOLUTION

print('Ordenada al origen b: {}'.format(b))
```

Ordenada al origen b: 2.2758950410682526

```
quizz.eval_numeric('4', b)
------
4 | Tu resultado es correcto.
```

9.4 Ejercicio 4.

Construir una recta usando los valores de m y b calculados en los ejercicios anteriores como sigue: * Construir un arreglo para x, de nombre xr0, usando alguna función de numpy (**el arreglo debe ser de 10 elementos**):

```
xr0 = np. ...
```

• Evaluar y = mx + b usando el arreglo xr0 para generar el arreglo yr0:

```
yr0 = ...
```

```
# Construcción de las rectas
# xr0 = np....
# yr0 = ...

### BEGIN SOLUTION
# Construcción de la recta
xr0 = np.linspace(x0.min(), x0.max(), 10)
yr0 = m * xr0 + b

file_answer.write('5', xr0, 'Recuerda que el arreglo debe tener 10 elementos, che
file_answer.write('6', yr0, 'Solo tienes que implementar la fórmula de la recta u

### END SOLUTION

print(xr0)
print(yr0)
```

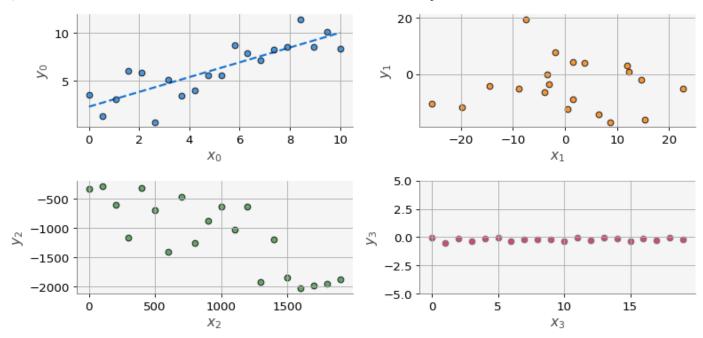
```
quizz.eval_numeric('5', xr0)
quizz.eval_numeric('6', yr0)
```

5 | Tu resultado es correcto.

6 | Tu resultado es correcto.

Si realizaste correctamente los ejercicios 1-4, entonces la siguiente celda de código graficará los cuatro conjuntos de datos y en la primera gráfica se verá la línea recta que construiste.

NOTA. En esta graficación estamos usando la biblioteca macti.visual.



9.5 Ejercicio 5.

Construir la función media(x) para calcular la media de un conjunto de datos. La función debe recibir como entrada el arreglo con los datos, x, y regresa la media de los mismos. Probar la función para los datos x0 y y0 como sigue:

```
X0 = media(x0)
Y0 = media(y0)
```

```
# Función media()
# def media (x):
# ...

### BEGIN SOLUTION
def media(x):
    xm = 0.0
    for xi in x:
        xm += xi
    return xm / N

X0 = media(x0)
Y0 = media(y0)

file_answer.write('7', X0, 'Revisa la definición de la media y la implementación
file_answer.write('8', Y0, 'Revisa la definición de la media y la implementación
### END SOLUTION
```

```
print('Media de x0 : {}'.format(X0))
print('Media de y0 : {}'.format(Y0))
```

Media de x0 : 5.0

Media de y0 : 6.138669185891269

```
quizz.eval_numeric('7', X0)
quizz.eval_numeric('8', Y0)
```

7 | Tu resultado es correcto.

8 | Tu resultado es correcto.

9.6 Ejercicio 6.

Construir la función mincua(x, y) para calcular m y b de un conjunto de datos. La función recibe como entrada los arreglos de datos, x, y, y regresa m y b. Calcular m y b para los conjuntos de datos:

- (x_1, y_1) , almacenar m y b en las variables m1 y b1 respectivamente.
- (x_2, y_2) , almacenar m y b en las variables m2 y b2 respectivamente.
- (x_3, y_3) , almacenar m y b en las variables m3 y b3 respectivamente.

```
# Función mincua()
# def mincua (x):
# ...
#

### BEGIN SOLUTION

def mincua(x, y):
    # Cálculo de la media
    X = media(x)
    Y = media(y)

# Cálculo de m

Sxx = 0

Sxy = 0

for xi, yi in zip(x, y):
    Sxy += xi * (yi - Y)
    Sxx += xi * (xi - X)

m = Sxy / Sxx
```

```
# Cálculo de b
b = Y - m * X

return m, b
### END SOLUTION
```

```
# Cálculo de m y b
# m1, b1 = ...
# ...

### BEGIN SOLUTION
m1, b1 = mincua(x1, y1)
m2, b2 = mincua(x2, y2)
m3, b3 = mincua(x3, y3)

file_answer.write('9' , [m1, b1], 'Checa que ejecutaste la función mincua(x,y) cc
file_answer.write('10', [m2, b2], 'Checa que ejecutaste la función mincua(x,y) cc
file_answer.write('11', [m3, b3], 'Checa que ejecutaste la función mincua(x,y) cc

### END SOLUTION

print('m1 = {}, \t b1 = {}'.format(m1, b1))
print('m2 = {}, \t b2 = {}'.format(m2, b2))
print('m3 = {}, \t b3 = {}'.format(m3, b3))
```

```
m1 = -0.02002336877662938, b1 = -3.9396674988126574

m2 = -0.86095919430528, b2 = -308.1742770138992

m3 = 0.003809973693633117, b3 = -0.24601956385565651
```

```
quizz.eval_numeric('9', [m1, b1])
quizz.eval_numeric('10', [m2, b2])
quizz.eval_numeric('11', [m3, b3])
```

```
9 | Tu resultado es correcto.

10 | Tu resultado es correcto.

11 | Tu resultado es correcto.
```

9.7 Ejercicio 7.

Construir las rectas de cada conjunto de datos como sigue:

- Usando m1 y b1 construir los arreglos de coordenadas xr1 y yr1.
- Usando m2 y b2 construir los arreglos de coordenadas xr2 y yr2.
- Usando m3 y b3 construir los arreglos de coordenadas xr3 y yr3.

```
# Construcción de las rectas
\# xr1 = np.linspace(...)
# yr1 = ...
# ...
### BEGIN SOLUTION
# Construcción de las rectas
xr1 = np.linspace(x1.min(), x1.max(), 10)
yr1 = m1 * xr1 + b1
xr2 = np.linspace(x2.min(), x2.max(), 10)
yr2 = m2 * xr2 + b2
xr3 = np.linspace(x3.min(), x3.max(), 10)
yr3 = m3 * xr3 + b3
file_answer.write('12', xr1, 'El arreglo xr1 no está bien construido.')
file_answer.write('13', yr1, 'El arreglo yr1 no está bien evaluado. Checa la fórm
file_answer.write('14', xr2, 'El arreglo xr2 no está bien construido.')
file_answer.write('15', yr2, 'El arreglo yr2 no está bien evaluado. Checa la fórm
file answer.write('16', xr3, 'El arreglo xr3 no está bien construido.')
file_answer.write('17', yr3, 'El arreglo yr3 no está bien evaluado. Checa la fórm
file_answer.to_file('q2')
### END SOLUTION
```

El directorio :/home/jovyan/HeCompA/.ans/03_AnalisisNumerico/ ya existe Respuestas y retroalimentación almacenadas.

```
12.66666667 14.77777778 16.88888889 19. ]

[-0.24601956 -0.23797629 -0.22993301 -0.22188973 -0.21384645 -0.20580317 -0.1977599 -0.18971662 -0.18167334 -0.17363006]
```

```
quizz.eval_numeric('12', xr1)
quizz.eval_numeric('13', yr1)
quizz.eval_numeric('14', xr2)
quizz.eval_numeric('15', yr2)
quizz.eval_numeric('16', xr3)
quizz.eval_numeric('17', yr3)
```

12 | Tu resultado es correcto.

13 | Tu resultado es correcto.

14 | Tu resultado es correcto.

15 | Tu resultado es correcto.

16 | Tu resultado es correcto.

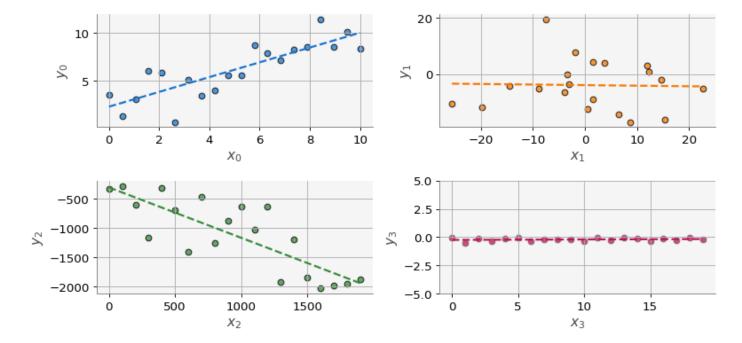
17 | Tu resultado es correcto.

Si caculaste todo correctamente, entonces la siguiente celda de código graficará los cuatro conjuntos de datos junto con las líneas rectas que construiste.

```
vis.scatter(3, x2, y2, fc='C2', ec='k', alpha=0.75)

vis.plot(4, xr3, yr3, c='C3', lw=2, ls = '--')
vis.scatter(4, x3, y3, fc='C3', ec='dimgrey', alpha=0.75)

vis.tight_layout()
vis.grid()
vis.show()
```



10 Apéndice A: Deducción del método.

Dado el conjunto de datos:

x_0	x_1	x_2	• • •	x_N
y_0	y_1	y_2		y_N

lo que en principio desearíamos es que se cumpliera que:

$$y_i = mx_i + b$$
 para $i = 0, \ldots, N$

que es equivalente a

$$0=mx_i+b-y_i ext{ para } i=0,\ldots,N,$$

Pero la ecuación (A.1) no se cumple en general, de tal manera que lo que se pide es que las desviaciones de cada punto con respecto de la recta sean pequeñas.

En el caso de este método, la desviación se define como la diferencia del valor y_i con respecto de la recta elevada al cuadrado, es decir: $(mx_i+b-y_i)^2$. Y para calcular la desviación global se suman todas las diferencias, por

lo que obtenemos:

$$f(m,b)=\sum_{i=1}^N(mx_i+b-y_i)^2$$

Observa que del lado derecho hemos puesto f(m,b) es decir, una función que depende de la pendiente m y de la ordenada al origen b.

El valor de la función f (la desviación global) depende de m y b; entonces para encontrar los valores de m y b más adecuados, debemos minimizar f con respecto a esas variables.

Recordando nuestras clases de cálculo, sabemos que para minimizar una función, debemos calcular su derivada, igualarla a cero y resolver para encontrar los puntos críticos (máximos y mínimos). En este caso, debemos derivar con respecto a m y con respecto a b, y luego resolver un sistema de dos ecuaciones. Veamos como:

$$rac{\partial f}{\partial m} = rac{\partial}{\partial m} \Biggl(\sum_{i=1}^N (mx_i + b - y_i)^2 \Biggr) = 2 \sum_{i=1}^N x_i ig(mx_i + b - y_i ig) = 0 \hspace{1cm} ext{(A.2)}$$

$$rac{\partial f}{\partial b} = rac{\partial}{\partial b} \Biggl(\sum_{i=1}^N (mx_i + b - y_i)^2 \Biggr) = 2 \sum_{i=1}^N \left(mx_i + b - y_i
ight) = 0 \hspace{1cm} ext{(A.3)}$$

De la ecuación (A.3) tenemos que:

$$m\sum_{i=1}^{N}x_{i}+\sum_{i=1}^{N}b-\sum_{i=1}^{N}y_{i}=0$$

y despejando b obtenemos:

$$b = \underbrace{\frac{1}{N} \sum_{i=1}^{N} y_i}_{ar{y}} - m \underbrace{\frac{1}{N} \sum_{i=1}^{N} x_i}_{ar{x}} = ar{y} - m ar{x}$$
 (A.4)

Ahora sustituimos (A.4) en (A.2) y obtenemos:

$$\sum_{i=1}^N x_iig(mx_i+ar{y}-mar{x}-y_iig)=0$$

Ahora despejamos m:

$$m = rac{\sum_{i=1}^{N} x_i (y_i - ar{y})}{\sum_{i=1}^{N} x_i (x_i - ar{x})}$$
 (A.5)

Las ecuaciones (A.4) y (A.5) proporcionan los valores de m y b de un punto crítico de la función f(m,b). Falta demostrar que ese punto crítico es un mínimo. Para ello se deben calcular las derivadas segundas $(\frac{\partial}{\partial^2 m}, \frac{\partial}{\partial^2 b}, \frac{\partial}{\partial b})$

 $\dfrac{\partial}{\partial m \partial b}$) y ver que se cumplen los criterios necesarios.